

DATA SCIENCE - DOCUMENTACIÓN TÉCNICA

# FinSightAI Data Science

Python - Pandas - Scikit-learn - Machine Learning

---

Pipeline de análisis, entrenamiento y evaluación  
de modelos financieros



HACKATHON ONE - PROYECTOS G9

**G9 Team 29 - TwentyNine Devs**

Alura - Oracle - No Country | Versión 1.0.0 | Agosto 2026

## 1. Resumen ejecutivo

El módulo de Data Science de **FinSightAI** constituye la base analítica y predictiva del MVP. Transforma información financiera y transaccional en variables estructuradas para clasificar movimientos, caracterizar el comportamiento económico del usuario y generar artefactos reutilizables por el AI-Service. El pipeline cubre generación y validación de datos sintéticos, EDA, limpieza, ingeniería de atributos, entrenamiento, evaluación, validación cruzada, interpretabilidad, serialización y pruebas de recarga.

## 2. Generación y validación de datos sintéticos

El generador propio produce **1.000 usuarios** (USR0001-USR1000), **12 meses** de historial y utiliza la **semilla 29** para favorecer la reproducibilidad. Incorpora categorías, descripciones, recurrencia, rangos de monto, reglas de coherencia y un **reporte\_validacion\_dataset.json**.

| Perfil      | Peso | Ingreso USD | Ratio gasto | Ratio deuda |
|-------------|------|-------------|-------------|-------------|
| Ahorrador   | 20%  | 1.800-7.000 | 0.38-0.58   | 0.00-0.15   |
| Equilibrado | 35%  | 1.500-6.500 | 0.55-0.72   | 0.04-0.22   |
| Ajustado    | 25%  | 1.200-5.000 | 0.68-0.84   | 0.10-0.30   |
| Consumista  | 10%  | 1.600-7.000 | 0.78-0.96   | 0.10-0.32   |
| Endeudado   | 10%  | 1.200-5.200 | 0.72-0.92   | 0.32-0.55   |

**Nota:** estos perfiles introducen diversidad sintética; no son las etiquetas finales del modelo: **Saludable, En observación y En riesgo**.

## 3. Datasets resultantes

| Dataset                      | Registros | Cols. | Propósito                                    |
|------------------------------|-----------|-------|----------------------------------------------|
| usuarios_sinteticos.csv      | 1.000     | 11    | Información financiera por usuario           |
| transacciones_sinteticas.csv | 74.532    | 10    | Historial de movimientos                     |
| usuarios_features.csv        | 1.000     | 27    | Variables para perfil financiero             |
| transacciones_features.csv   | 74.532    | 21    | Atributos textuales, temporales y monetarios |

## 4. Exploración de datos (EDA)

El EDA inspecciona estructura, tipos, nulos, duplicados, distribuciones e inconsistencias. Se controlan identificadores, fechas, montos, categorías admitidas e integridad referencial entre usuarios y transacciones.

| Perfil objetivo | Cantidad | Participación |
|-----------------|----------|---------------|
| En observación  | 403      | 40,3%         |
| En riesgo       | 330      | 33,0%         |
| Saludable       | 267      | 26,7%         |

## 5. Procesamiento e ingeniería de atributos

**Transacciones:** normalización de descripción y variables temporales, logaritmo del monto, transacción grande, longitud de descripción, cantidad de palabras y recurrencia. **Usuarios:** agregaciones de movimientos, estadísticas de monto, recurrencia, diversidad de categorías y ratios financieros.

| 1                | 2                | 3        | 4             | 5          | 6                 |
|------------------|------------------|----------|---------------|------------|-------------------|
| Datos sintéticos | Validación / EDA | Features | Entrenamiento | Evaluación | Joblib + metadata |

## 6. Modelos de Machine Learning

**Clasificador de transacciones.** Utiliza principalmente **descripcion\_limpia** y combina TF-IDF de palabras y caracteres para tolerar variaciones ortográficas y expresiones equivalentes. El monto, fecha, medio de pago y recurrencia no son señales principales para decidir la categoría.

**16 clases:** Alimentación, Compras, Deudas, Educación, Entretenimiento, Impuestos, Otros, Otros ingresos, Reintegro, Salario, Salud, Servicios, Transferencia recibida, Transporte, Venta y Vivienda.

**Clasificador de perfil.** Utiliza diez variables financieras agregadas para clasificar al usuario en **Saludable**, **En observación** o **En riesgo**, representando gasto, deuda, ahorro, recurrencia, diversidad y comportamiento transaccional.

## 7. Evaluación y validación

| Modelo / evaluación         | Accuracy | Precision | Recall | F1     |
|-----------------------------|----------|-----------|--------|--------|
| Transacciones - Hold-Out    | 1.0000   | 1.0000    | 1.0000 | 1.0000 |
| Transacciones - CV agrupada | 0.9967   | 0.9858    | 0.9771 | 0.9767 |
| Perfil - Hold-Out           | 0.8760   | 0.8771    | 0.8885 | 0.8817 |
| Perfil - Validación cruzada | 0.8960   | 0.8992    | 0.9053 | 0.9013 |

**Interpretación:** el Hold-Out perfecto del modelo transaccional debe leerse considerando la naturaleza sintética de los datos. La CV agrupada aporta una comprobación adicional, pero la validación definitiva requiere datos reales e independientes.

## 8. Inferencia e interpretabilidad

El notebook simula el comportamiento esperado en producción. **prediction.py** implementa carga de modelos, normalización, alias, construcción de features, *predict*, *predict\_proba*, confianza y advertencias, conectando experimentación e inferencia.

| Entrada                    | Procesamiento            | Salida                                |
|----------------------------|--------------------------|---------------------------------------|
| Descripción de transacción | Normalización + pipeline | Categoría, confianza y probabilidades |
| Datos financieros          | Features + clasificador  | Perfil, probabilidades y métricas     |
| Usuario + historial        | Análisis + reglas        | Categorías y recomendaciones          |

## 9. Serialización y artefactos

Los pipelines completos se guardan con **Joblib** y se validan mediante recarga y predicciones de prueba. Esto conserva preprocesamiento y clasificador en un mismo artefacto.

| Artefacto                        | Propósito                              |
|----------------------------------|----------------------------------------|
| FinSightAI_DataScience_1.0.ipynb | Pipeline integral                      |
| clasificador_gastos.joblib       | Clasificador de 16 categorías          |
| clasificador_perfil.joblib       | Clasificador de perfil                 |
| metadata_modelos.json            | Versiones, features, clases y contrato |
| metricas_modelos.csv             | Resultados de evaluación               |
| prediction.py                    | Inferencia desde AI-Service            |
| *_features.csv                   | Datasets procesados                    |

## 10. Integración con AI-Service

| Data Science                | Artefactos            | AI-Service                |
|-----------------------------|-----------------------|---------------------------|
| Generación / EDA / features | CSV procesados        | Carga de datos            |
| Entrenamiento               | Modelos .joblib       | Predicción                |
| Evaluación                  | Métricas + metadata   | Versionado / trazabilidad |
| Pruebas de recarga          | Pipeline reproducible | Inferencia consistente    |

## 11. Casos de uso de Data Science

| ID      | Caso de uso                         | Actor / resultado                     |
|---------|-------------------------------------|---------------------------------------|
| UC-DS01 | Preparar datos transaccionales      | Data Scientist - dataset limpio       |
| UC-DS02 | Generar atributos financieros       | Data Scientist - variables derivadas  |
| UC-DS03 | Entrenar clasificador transaccional | Data Scientist - modelo de categorías |
| UC-DS04 | Entrenar clasificador de perfil     | Data Scientist - modelo de perfil     |
| UC-DS05 | Evaluar y validar modelos           | Data Scientist - métricas y CV        |
| UC-DS06 | Serializar modelos                  | Data Scientist - artefactos Joblib    |
| UC-DS07 | Ejecutar inferencia                 | AI-Service - predicción y confianza   |

## 12. Reproducibilidad y controles

El generador fija **semilla 29** y el metadata registra **random\_state 42**. El pipeline exporta datasets procesados, métricas y metadata, ejecuta smoke tests y verifica la recarga de modelos serializados.

## 13. Limitaciones y trabajo futuro

- Datos sintéticos: requieren validación con datos reales e independientes.
- El vocabulario deberá ampliarse para descripciones bancarias reales.
- Patrones sintéticos regulares pueden elevar algunas métricas.
- Score y recomendaciones no constituyen calificación crediticia ni asesoramiento profesional.
- Los modelos pueden reproducir sesgos.
- Producción requiere monitoreo, recalibración, detección de drift y protección de datos.

**Trabajo futuro:** datos reales anonimizados, vocabulario ampliado, calibración de probabilidades, monitoreo, detección de deriva y revisión con especialistas.

## 14. Trazabilidad con los requisitos del Hackathon

| Requisito                    | Cobertura Data Science                                  |
|------------------------------|---------------------------------------------------------|
| EDA                          | Exploración, calidad y distribuciones                   |
| Limpieza y validación        | Controles estructurales e integridad referencial        |
| Ingeniería de atributos      | Variables textuales, temporales, monetarias y agregadas |
| Clasificación de movimientos | Clasificador de 16 categorías                           |
| Perfil financiero            | Saludable / En observación / En riesgo                  |
| Evaluación / validación      | Accuracy, Precision, Recall, F1, Hold-Out y CV          |
| Serialización                | Joblib + metadata + métricas                            |
| Integración                  | Artefactos consumidos por AI-Service                    |

## 15. Conclusión

FinSightAI Data Science implementa un pipeline integral alineado con el MVP: generación y validación de datos, EDA, ingeniería de atributos, clasificación de transacciones, análisis de perfil, evaluación, serialización e inferencia. Los resultados demuestran la viabilidad técnica del enfoque, documentando a la vez las limitaciones del uso de datos sintéticos y la necesidad de validación real, monitoreo y control de sesgos.

**FinSightAI · TwentyNine Devs · G9 Team 29**  
Hackathon ONE · Proyectos G9 · Alura · Oracle · No Country